ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

AI23 (23TNT1), FIT@HCMUS, VNUHCM

Chinese OCR

Đề tài: Fine-tune PaddleOCR cho bài toán phát hiện chữ Hán Nôm

Môn học: Nhập môn xử lý ngôn ngữ tự nhiên - CQ2023/22

Sinh viên thực hiện:
Đinh Đức Anh Khoa (23122001)
Nguyễn Lê Hoàng Trung (23122004)
Đinh Đức Tài (23122013)

Giáo viên hướng dẫn:
PGS.TS. Đinh Điền
TS. Nguyễn Hồng Bửu Long
TS. Lương An Vinh
CN. Trần Kim Phát

Ngày 3 tháng 1 năm 2026

Mục lục

1 Giới thiệu **2**

2 Bộ dữ liệu NomNaOCR và CWKB **3**
2.1 Giới thiệu . . . 3
2.1.1 NomNaOCR . . . 3
2.1.2 CWKB - Toàn tập Phật giáo Hàn Quốc . . . 3
2.2 Thu thập và xử lý dữ liệu . . . 3

3 Fine-tune PP-OCRv5 **4**
3.1 Giới thiệu PP-OCRv5 . . . 4
3.2 Kiến trúc mô hình . . . 4
3.3 Tinh chỉnh mô hình . . . 4
3.3.1 Thiết lập môi trường . . . 4
3.3.2 Cấu hình siêu tham số . . . 4
3.3.3 Quá trình tinh chỉnh . . . 5
3.3.4 Quy trình đánh giá . . . 5
3.3.5 Xuất mô hình . . . 5

4 Kết quả và phân tích **6**
4.1 Minh họa . . . 6
4.2 Kết quả . . . 8
4.3 Phân tích . . . 9

5 Kết luận, đánh giá **10**
5.1 Kết luận . . . 10
5.2 Đánh giá . . . 10

1 Giới thiệu

Đây là tài liệu báo cáo cho **Đồ án Chinese OCR**, với đề tài **Fine-tune PaddleOCR cho bài toán phát hiện chữ trên bộ dữ liệu NomNaOCR**, môn **Nhập môn xử lý ngôn ngữ tự nhiên - CQ2023/22**, Khoa Công nghệ thông tin, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM.

Báo cáo được thực hiện bởi nhóm các thành viên:

- Đinh Đức Anh Khoa (23122001)
- Nguyễn Lê Hoàng Trung (23122004)
- Đinh Đức Tài (23122013)

Đường dẫn repository Github: https://github.com/ductai05/NLP-ChineseOCR [1]

Bảng phân công nhiệm vụ cho từng thành viên:

Họ và tên	MSSV	Nhiệm vụ
Đinh Đức Anh Khoa	23122001	- Thu thập, xử lý dữ liệu và chuẩn bị dữ liệu. Viết báo cáo.
Nguyễn Lê Hoàng Trung	23122004	- Fine-tune PP-OCRv5 cho bài toán phát hiện chữ. - Minh họa kết quả phát hiện chữ.
Đinh Đức Tài	23122013	- Viết báo cáo Fine-tune PP-OCRv5. - Phân tích kết quả Fine-tune.

Các công nghệ sử dụng:

- **Python**: Python là một ngôn ngữ lập trình bậc cao, đa năng. Python được sử dụng rộng rãi trong các lĩnh vực như phát triển web, khoa học dữ liệu, trí tuệ nhân tạo, và tự động hóa.
- **PP-OCRv5**: PP-OCRv5 là giải pháp nhận dạng văn bản mới nhất của PaddlePaddle, hỗ trợ tiếng Trung, tiếng Anh và tiếng Nhật.
- **Kaggle**: Kaggle là một nền tảng trực tuyến dành cho khoa học dữ liệu và học máy, cung cấp môi trường chạy code Python và tài nguyên miễn phí như GPU, TPU.

2 Bộ dữ liệu NomNaOCR và CWKB

2.1 Giới thiệu

2.1.1 NomNaOCR

NomNaOCR [2] là bộ dữ liệu OCR lớn nhất hiện nay cho chữ Hán-Nôm ở Việt Nam, được xây dựng từ ba công trình lịch sử, văn học có giá trị gồm Lục Vân Tiên (Nguyễn Đình Chiểu), Truyện Kiều (các bản 1866–1872, Nguyễn Du) và Đại Việt Sử Ký Toàn Thư. Bộ dữ liệu gồm *2.953* trang bản thảo viết tay thu thập từ Vietnamese Nôm Preservation Foundation.

2.1.2 CWKB - Toàn tập Phật giáo Hàn Quốc

Toàn tập Phật giáo Hàn Quốc [3] (Complete Works of Korean Buddhism - CWKB) là bộ sưu tập văn học Phật giáo do người Hàn Quốc sáng tác và biên soạn từ thời Silla đến thời Joseon. Đây là nguồn tư liệu gốc quan trọng nhất để nghiên cứu lịch sử tư tưởng Hàn Quốc cũng như Phật giáo Hàn Quốc.

2.2 Thu thập và xử lý dữ liệu

Dữ liệu được thu thập từ hai nguồn chính. Thứ nhất là bộ dữ liệu **NomNaOCR** được nhóm tải trực tiếp từ nền tảng Kaggle. Thứ hai là bộ dữ liệu **Toàn tập Phật giáo Hàn Quốc (CWKB)**, được thu thập bằng phương pháp crawl từ các nguồn công bố chính thức sau đó tiến hành làm sạch dữ liệu và gán nhãn thủ công.

Sau khi thu thập, toàn bộ ảnh từ hai nguồn được chuẩn hóa và lưu trữ theo cùng một cấu trúc thư mục. Mỗi ảnh đều có nhãn tương ứng được ghi trong file `det_gt.txt` để phục vụ cho việc tinh chỉnh mô hình cho tác vụ phát hiện chữ.

Phần dữ liệu validation gốc của NomNaOCR được chuyển hoàn toàn sang tập test. Phần train của NomNaOCR cùng toàn bộ dữ liệu CWKB được trộn ngẫu nhiên và chia theo tỷ lệ 80/20 để tạo tập train và tập validation.

Toàn bộ tên ảnh được đổi theo định dạng thống nhất `<Tên sách>_<Tên ảnh>.jpg`, giúp dễ dàng truy vết nguồn gốc dữ liệu và thuận tiện trong quá trình huấn luyện, đánh giá mô hình. Cấu trúc thư mục cuối cùng của bộ dữ liệu được tổ chức thành ba tập `Train`, `Val` và `Test`, với số lượng ảnh lần lượt là 2253, 564 và 594 ảnh.

3 Fine-tune PP-OCRv5

3.1 Giới thiệu PP-OCRv5

PP-OCRv5 [4] là một hệ thống OCR nhẹ nhưng có độ chính xác cao, được thiết kế để hoạt động hiệu quả trong nhiều tình huống khác nhau. PP-OCRv5 hỗ trợ nhiều loại chữ viết như tiếng Trung, tiếng Anh, tiếng Nhật.

PP-OCRv5 có 4 phần chính: Module tiền xử lý hình ảnh (gồm module phân loại hướng ảnh tài liệu và module khôi phục hình ảnh), mô hình phát hiện văn bản, mô hình phân loại hướng dòng văn bản, mô hình nhận dạng văn bản. Trong 2 phiên bản của mô hình phát hiện văn bản là *server* và *mobile*, mô hình *server* được chọn để tinh chỉnh (định danh: `PP-OCRv5_server_det`)

3.2 Kiến trúc mô hình

Mô hình *PP-OCRv5 Server Detection* (`PP-OCRv5_server_det`) sử dụng thuật toán *Differentiable Binarization (DB)* kết hợp các kĩ thuật tiên tiến như chiến lược huấn luyện *Dynamic Scale-aware Refinement (DSR)* và tăng cường dữ liệu từ `ERNIE-4.5-VL-424B-A47B` để giải bài toán phát hiện văn bản. Mô hình bao gồm các thành phần chính:

- **Backbone**: PP-HGNetV2_B4, được áp dụng kĩ thuật chưng cất tri thức từ GOT-OCR2.0.
- **Neck**: LKPAN (Large Kernel Path Aggregation Network)
- **Head**: PFHeadLocal (Parallel Fusion Head)

3.3 Tinh chỉnh mô hình

3.3.1 Thiết lập môi trường

Quá trình tinh chỉnh được thực hiện trên nền tảng Kaggle với cấu hình như sau:

- **GPU**: 2× NVIDIA Tesla T4 (VRAM: 15,360 MiB mỗi GPU). CUDA 12.8, cuDNN 9.2.
- **Framework, mã nguồn OCR**: PaddlePaddle GPU và PaddleOCR.
- **Thư viện bổ sung**: paddleocr, scikit-image, albumentations, lmdb, rapidfuzz.

3.3.2 Cấu hình siêu tham số

Qua quá trình thử nghiệm, ngoại trừ số *epoch* được điều chỉnh giảm xuống 100, cấu hình siêu tham số gốc cho kết quả tối ưu nhất. Chi tiết các siêu tham số như sau:

- **Model**: Mô hình gốc `PP-OCRv5_server_det`. Kiến trúc chính: thuật toán `DB`, backbone `PPHGNetV2_B4`, neck `LKPAN` với 256 kênh đầu ra, head `PFHeadLocal` với $k = 50$.
- **Epoch**: Điều chỉnh giảm xuống 100.
- **Optimizer**: Sử dụng thuật toán **Adam** với các hệ số moment $\beta_1 = 0.9, \beta_2 = 0.999$. Tốc độ học khởi tạo là 0.001, tự động điều chỉnh theo chiến lược *Cosine Annealing* kèm theo 2 *epoch* khởi động. Hệ số L2 Regularization là 10^{-6}.

- **Loss Function**: Sử dụng hàm **DBLoss**, là tổ hợp có trọng số của:
  - Probability map loss (sử dụng DiceLoss, trọng số $\alpha = 5$).
  - Threshold map loss (sử dụng Binary Cross Entropy, trọng số $\beta = 10$).

  Tỉ lệ *Online Hard Example Mining (OHEM)* được đặt là 3:1 để mô hình học các mẫu khó.

- **Tăng cường dữ liệu**: Áp dụng chuỗi các biến đổi ngẫu nhiên để tăng tính đa dạng cho dữ liệu đầu vào:
  - Cắt ngẫu nhiên về kích thước cố định 640×640.
  - Xoay ảnh trong khoảng $[-10°, 10°]$ và thay đổi tỉ lệ ảnh từ $[0.5, 3.0]$.
  - Lật ngang ảnh với xác suất 0.5.

- **Hậu xử lý**: Để tái tạo bounding box từ bản đồ đặc trưng, sử dụng ngưỡng nhị phân $\tau = 0.3$, ngưỡng lọc box là 0.6 và tỉ lệ mở rộng vùng văn bản là 1.5.

3.3.3 Quá trình tinh chỉnh

Mô hình được khởi tạo từ bộ trọng số `PP-OCRv5_server_det_pretrained.pdparams` được huấn luyện trước. Quá trình tinh chỉnh áp dụng phương pháp **Full Fine-tuning**, cho phép lan truyền ngược cập nhật trọng số trên toàn bộ kiến trúc mạng (Backbone, Neck và Head). Việc huấn luyện được thực hiện phân tán song song trên 2 GPU.

Quá trình huấn luyện diễn ra trong 100 *epoch*. Hệ thống giám sát được cấu hình chi tiết như sau:

- **Ghi nhật ký**: Các chỉ số như Loss, thời gian xử lý, và tốc độ đọc dữ liệu được ghi lại sau mỗi 10 bước, với chỉ số loss được làm mịn qua cửa sổ 20 bước.

- **Đánh giá**: Mô hình được đánh giá trên tập validation ngay tại bước khởi đầu và lặp lại định kỳ sau mỗi 500 bước. Chỉ số **h-mean** được sử dụng làm tiêu chí chính để so sánh hiệu năng.

- **Lưu trữ**: Toàn bộ trạng thái mô hình được lưu định kỳ sau mỗi 10 *epoch*. Đồng thời, hệ thống tự động lưu trữ phiên bản mô hình đạt chỉ số h-mean cao nhất trên tập validation.

3.3.4 Quy trình đánh giá

Hiệu năng giữa mô hình gốc và mô hình sau khi tinh chỉnh được kiểm tra trên tập dữ liệu Test độc lập. Các chỉ số đánh giá chính bao gồm:

- **Precision**: Độ chính xác của các vùng văn bản được phát hiện.

- **Recall**: Tỷ lệ các vùng văn bản thực tế được phát hiện thành công.

- **H-mean (F1-Score)**: Trung bình điều hòa giữa Precision và Recall.

3.3.5 Xuất mô hình

Mô hình huấn luyện lưu trữ trọng số tại tệp `.pdparams` và trạng thái tối ưu hóa tại tệp `.pdopt`. Quá trình xuất sang dạng đồ thị tĩnh sẽ loại bỏ dữ liệu của bộ tối ưu hóa nhằm tạo ra tệp cấu trúc `.pdmodel` cùng tệp tham số `.pdiparams` giúp tối ưu tốc độ suy luận.

4 Kết quả và phân tích

4.1 Minh họa

Sau đây là một vài kết quả phát hiện chữ trên các bộ sách Lục Vân Tiên, Truyện Kiều:

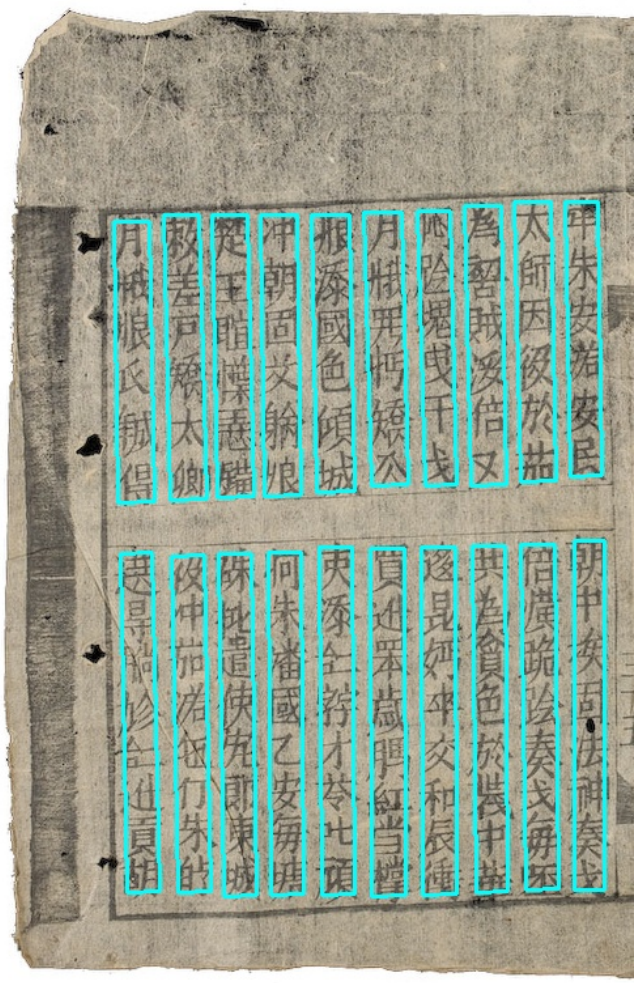

(a) Truyện Lục Vân Tiên

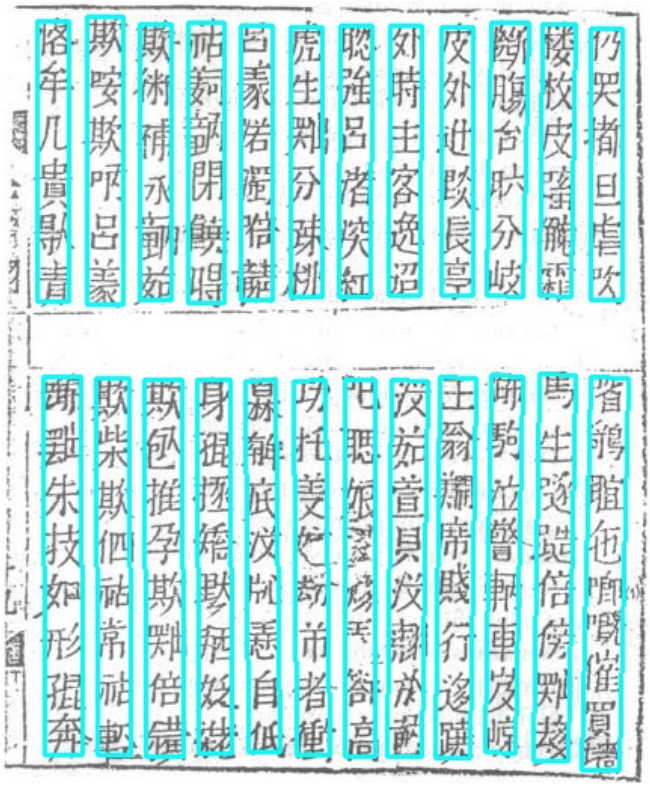

(b) Truyện Kiều

Hình 1: Các kết quả phát hiện chữ của mô hình đã được tinh chỉnh.

Để có góc nhìn trực quan, nhóm đã trích xuất hình ảnh các kết quả dự đoán tốt nhất (Hình 2) và tệ nhất (Hình 3) dựa trên chỉ số IoU và giá trị trung bình điều hòa H-mean, với đường viền màu xanh lá là nhãn gốc, đường viền màu đỏ là dự đoán của mô hình.

(a) H-mean: 1.0, Precision: 1.0, Recall: 1.0

(b) H-mean: 1.0, Precision: 1.0, Recall: 1.0

Hình 2: Các kết quả dự đoán **tốt** của mô hình.

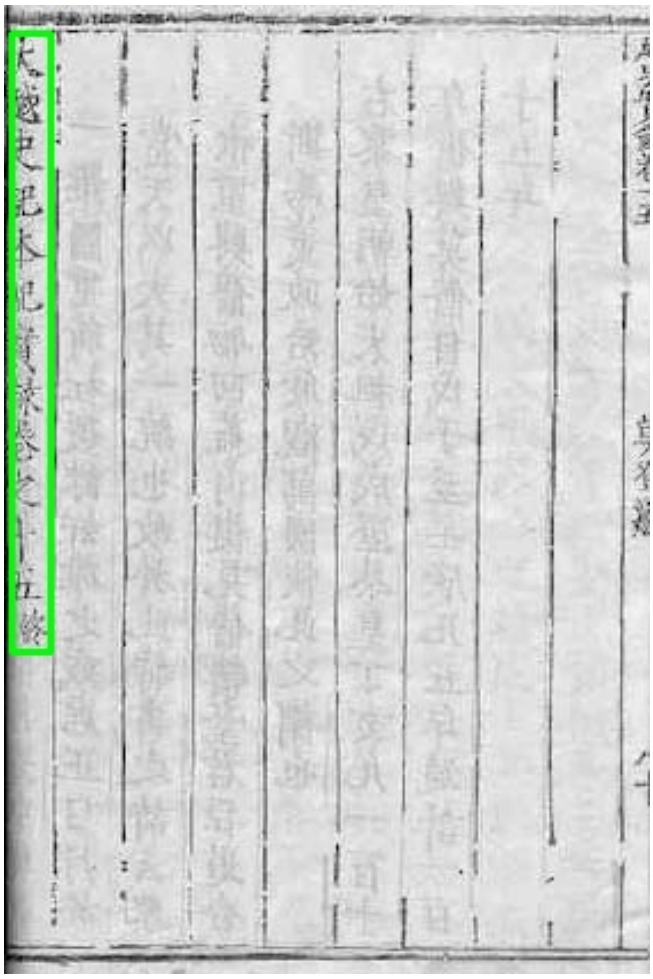

(a) H-mean: 0.0, Precision: 0.0, Recall: 0.0

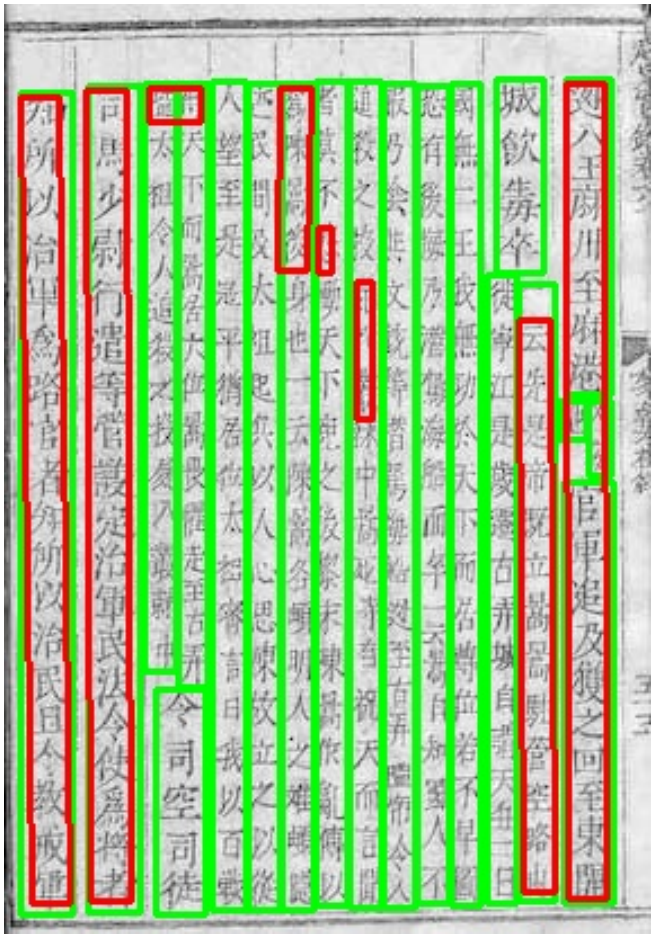

(b) H-mean: 0.21, Precision: 0.38, Recall: 0.15

Hình 3: Các kết quả dự đoán **tệ** của mô hình.

4.2 Kết quả

Việc đánh giá được thực hiện trên tập Test của bộ dữ liệu NomNaOCR. Bảng 1 so sánh hiệu suất giữa mô hình gốc (`PP-OCRv5_server_det`) và mô hình sau khi tinh chỉnh:

Metric	Mô hình gốc	Mô hình được tinh chỉnh
Precision	0.713	0.966
Recall	0.75	0.937
H-mean	0.731	**0.952**

Bảng 1: Kết quả đánh giá trên tập Test

4.3 Phân tích

Những nhận định sau được rút ra dựa trên quá trình huấn luyện và kết quả thực nghiệm:

- **Động lực huấn luyện:** Mô hình hội tụ rất nhanh. Hàm loss giảm mạnh ngay trong epoch đầu tiên (từ 4.12 xuống 1.38) dù đang trong giai đoạn khởi động tốc độ học (tốc độ học trong epoch đầu tăng dần từ 1.6^{-5} lên 4.6^{-4}). Chỉ số Hmean tăng trưởng ổn định, tiệm cận mức cao sau 20 epoch và đạt cực đại tại epoch thứ 64.
- **Hiệu suất theo đặc thù dữ liệu:** Có sự phân hóa rõ rệt về độ chính xác giữa các nguồn văn bản.
  - Các tác phẩm có chất lượng bản in/viết rõ nét như *Truyện Kiều* và *Lục Vân Tiên* đạt kết quả phát hiện chữ rất cao.
  - Bộ *Đại Việt sử ký toàn thư* cho kết quả thấp hơn do văn bản gốc chứa nhiều vùng chữ mờ, nhòe và xuống cấp theo thời gian.
- **Hạn chế về quy trình:** Thực nghiệm hiện tại chưa áp dụng trọn vẹn pipeline của PP-OCRv5, cụ thể là thiếu module tiền xử lý hình ảnh (gồm phân loại hướng với PP-LCNet và gỡ méo văn bản với UVDoc). Việc thiếu các bước chuẩn hóa đầu vào này là nguyên nhân chính khiến mô hình gặp khó khăn khi xử lý các trường hợp khó (chữ mờ) trong bộ *Đại Việt sử ký toàn thư*.

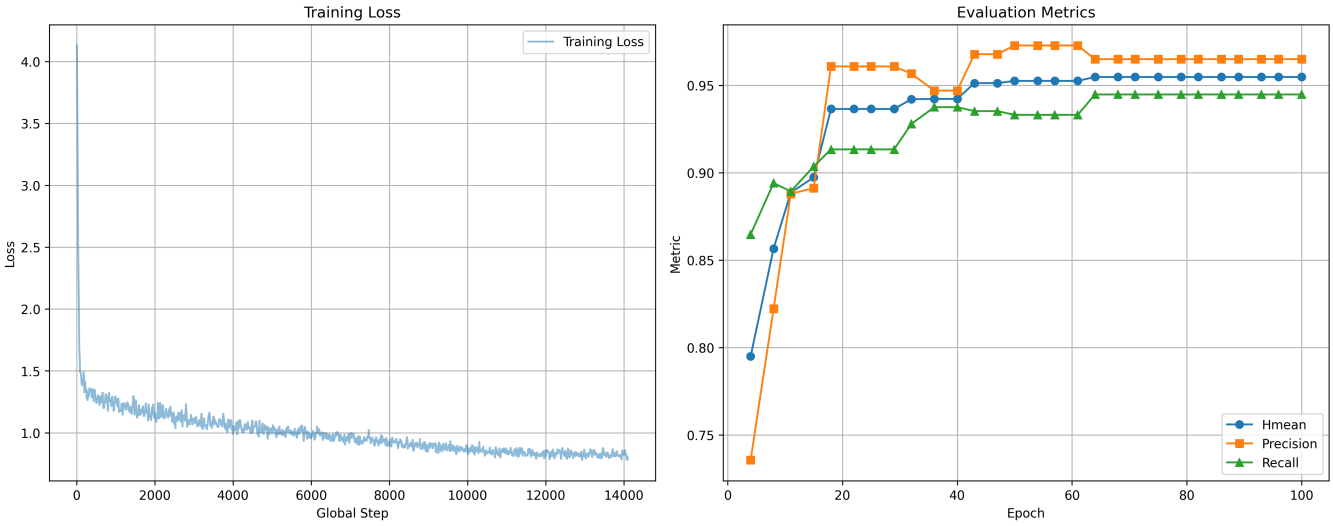

Hình 4: Biểu đồ DBLoss trên tập train và chỉ số Precision, Recall, Hmean trên tập validation

5 Kết luận, đánh giá

5.1 Kết luận

Tổng kết lại quá trình thực hiện đồ án, nhóm nghiên cứu đã hoàn thành các mục tiêu đề ra về việc xây dựng hệ thống phát hiện chữ Hán-Nôm. Cụ thể:

- Đã xây dựng thành công bộ dữ liệu huấn luyện chuẩn hóa từ hai nguồn dữ liệu lớn là *NomNaOCR* và *CWKB*, tạo nền tảng dữ liệu chất lượng cho bài toán.
- Thực hiện tinh chỉnh (fine-tune) thành công mô hình **PP-OCRv5** cho tác vụ phát hiện văn bản, đạt kết quả ấn tượng trên tập kiểm thử với chỉ số **H-mean đạt 0.952**, vượt trội so với mô hình gốc (0.731). Đã thực hiện phân tích kết quả mô hình.

5.2 Đánh giá

Đối với đồ án này, nhóm tự đánh giá **hoàn thành tốt và đầy đủ** các yêu cầu đã được đặt ra. Chi tiết như sau:

- Mô hình và dữ liệu: Tinh chỉnh thành công PP-OCRv5 trên CWKB và NomNaOCR.
- Đánh giá: Kết quả được đo lường đầy đủ bằng Precision, Recall và Hmean trên NomNaOCR.
- Tính minh bạch và đóng gói: Báo cáo rõ ràng các tham số huấn luyện (epoch, optimizer,...) và nộp đầy đủ checkpoint/config của mô hình tốt nhất.

Tài liệu

[1] Anh Khoa, Hoang Trung, and Duc Tai. NLP-ChineseOCR. https://github.com/ductai05/NLP-ChineseOCR, 2025.

[2] Hoang-Quan Dang, Duy-Anh Nguyen, Phu-Phuoc Pham, Ngoc-Thinh Nguyen, Tan Chau, Duc-Vu Ngo, Trung-Hieu Nguyen, Chau-Thang Phan, The-Hien Trinh, Minh-Tri Nguyen, and Trong-Hop Do. Nomnaocr: The first dataset for optical character recognition on han-nom script. In *2022 RIVF International Conference on Computing and Communication Technologies (RIVF)*, pages 476–481, 2022.

[3] Dongguk University. The Archive of the Cultural Heritage of Buddhist Records. https://kabc.dongguk.edu/, 2025.

[4] Cheng Cui, Ting Sun, Manhui Lin, Tingquan Gao, Yubo Zhang, Jiaxuan Liu, Xueqing Wang, Zelun Zhang, Changda Zhou, Hongen Liu, Yue Zhang, Wenyu Lv, Kui Huang, Yichao Zhang, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr 3.0 technical report, 2025.